

TravelTide – Final Report

Customer Analytics & Kundensegmentierung

Projektübersicht

TravelTide ist eine Online-Plattform für die Buchung von Flügen und Hotels. Ziel des Projekts war es, aus der transaktionalen Kundendatenbank verwertbare Erkenntnisse zu gewinnen und die aktive Kundschaft in aussagekräftige Segmente zu unterteilen. Dazu wurden die Daten aus fünf relationalen Quellen extrahiert, bereinigt, zu benutzerbezogenen Kennzahlen aggregiert und anschließend explorativ sowie mittels Clustering analysiert. Das Ergebnis ist ein Master-Datensatz auf **user_id**-Ebene, eine regelbasierte Segmentierung (8 Gruppen) und ein K-Means-Clustering der größten Kundengruppe (3 Sub-Cluster).

Zielsetzung des Projekts

- Aktive Nutzer:innen identifizieren und die relevanten Rohdaten (*users, sessions, flights, hotels*) bereitstellen.
- Datenqualität sicherstellen (Cleaning, fehlende Werte, Datentypen, Storno-/Rabattlogik).
- Verhaltens- und Umsatzkennzahlen je Kunde aufbauen (Feature Engineering).
- Kunden in homogene, marketingrelevante Segmente einteilen.
- Konkrete Handlungsempfehlungen für Marketing und Produktstrategie ableiten.

Datenfluss durch die Notebooks 01–05

- **01 – Data Filtering:** Extraktion der aktiven User aus der Neon-PostgreSQL-Datenbank.
- **02 – EDA:** Explorative Analyse der Rohdaten (*users, sessions, flights, hotels*).
- **03 – Features:** Cleaning & Feature Engineering → Master-Dataframe (*user_id*-Ebene).
- **04 – Group Build:** Regelbasierte Gruppenbildung / Kundensegmentierung.
- **05 – Clustering:** K-Means-Clustering der Gruppe „Standard Kunde“ → Sub-Cluster.

Grafik: *report/cluster_dashboard.png* fasst die wichtigsten Segment-Kennzahlen zusammen.

Die Notebooks im Überblick

01 – Datenfilterung (01_traveltide_data_filtering)

Verbindung zur Neon-PostgreSQL-Datenbank. Definition „aktiver User“: **session_start** $\geq$ **05.01.2023** und **> 7 Sessions**. Die vier Tabellen (users, sessions, flights, hotels) werden auf diesen Kundenkreis gefiltert und als CSV gespeichert. Ergebnis: die Analysebasis der aktiven Kundschaft.

02 – Explorative Datenanalyse (02_EDA)

Kennzahlen- und Visualisierungs-Dashboards zu allen vier Tabellen: Nutzer (Altersverteilung mit Schwerpunkt ca. 40–50 Jahre), Sessions (Buchungs-/Storno-Verhalten, Rabatte, Session-Dauer), Flüge (Preis pro Sitzplatz, Airlines, Saisonalität) und Hotels (Ketten, Städte, Preisniveau). Liefert die inhaltliche Grundlage für die weitere Analyse.

03 – Feature Engineering (03_features)

Bereinigung und Zusammenführung der Tabellen (Left Joins über *trip_id*), Kostenberechnung für Flüge/Hotels unter Berücksichtigung von Rabatten und Stornierungen sowie Aggregation auf *user_id*-Ebene (Sessions, Trips, Ausgaben, Rabattnutzung, Stornoquote, Gepäck, Hotelnächte, Demografie). Ergebnis: **master_features.csv** mit **5.782 Kunden**. Auffällige Korrelationen: Hotelnächte $\leftrightarrow$ Hotelkosten 0,53; Gepäck $\leftrightarrow$ Flugkosten 0,33; Stornorate $\leftrightarrow$ Flugkosten 0,27.

04 – Gruppenbildung (04_group_build)

Regelbasierte Segmentierung über Schwellenwerte (Top-10%-Spender, überdurchschnittliche Hotel-/Flugkosten, Top-25% Trips bzw. Buchungsratio, Alter < 20 / > 60). Ergebnis: **8 Segmente**; größte Gruppe „**Standard Kunde**“ mit **2.070 Kunden (35,8%)**.

05 – Clustering (05_clustering)

Filterung der Gruppe „Standard Kunde“, Standardisierung der Features (StandardScaler) und K-Means-Clustering. Die optimale Clusterzahl wird über Elbow-Methode und Silhouette-Score bestimmt: **k = 3**. Ergebnis: drei neue, klar getrennte Sub-Cluster.

Verwendete Methoden

- **Data Cleaning:** Typkonvertierung, Umgang mit fehlenden Werten, Bereinigung der Storno-/Rabattlogik und Boolean-Felder.
- **EDA:** Deskriptive Statistik, Histogramme, Boxplots, Balken- und Streudiagramme, Korrelations-Heatmaps.
- **Feature Engineering:** Zusammenführung über *trip_id*, Kosten- und Kennzahlen-Aggregation auf *user_id*-Ebene.
- **Clustering:** StandardScaler + K-Means, Bestimmung von *k* via Elbow-Methode und Silhouette-Score (*k* = 3).

Hauptergebnisse & Erkenntnisse aus dem Clustering

K-Means (k = 3) auf der Gruppe „Standard Kunde“ (2.070 Kunden) identifiziert drei unterscheidbare Verhaltensmuster:

- **Cluster 0 – Treue Wertkäufer:** Ø 43,7 Jahre, höchste Ausgaben (\$1.545,21) und Conversion (41%), 3,39 Reisen, 0 % Storno, wenig Rabatte – stabilstes und profitabelstes Segment.
- **Cluster 1 – Low-Engagement Surfer:** Ø 35,6 Jahre, geringster Umsatz (\$471,62), nur 1,69 Reisen und 21% Conversion – viel Browsing, hohe Kaufhürde.
- **Cluster 2 – Deal-Seeker & Storno-Risiko:** Ø 37,8 Jahre, hoher Umsatz (\$1.438,21), 3,10 Reisen, intensive Rabattnutzung (2,36/2,00) und **12% Stornorate** – das einzige Cluster mit nennenswerten Stornierungen.

Kernaussage: Auch innerhalb der homogen wirkenden Gruppe existieren klar trennbare Muster – von loyalen Wertkunden über preisgetriebene Schnäppchenjäger bis zu stornoaffinen, rabattfokussierten Kunden. Das ermöglicht eine zielgenaue Ansprache.

Wichtigste Visualisierungen (Ordner report)

EDA & Feature-Analyse: Altersverteilung_der_Kunden.png, Korrelations_Heatmap.png, Verteilung_der_Flugkosten.png, Verteilung_der_Hotelausgaben.png, Flugkosten_vs_Hotelkosten.png

Segmentierung: Verteilung_der_Kundensegmente.png, Venn-Diagramm_überdurchschnittliche_Spender.png, Kunden-Segmentierung_nach_überdurchschnittlichen_Ausgaben.png

Clustering: elbow_silhouette_plot.png (k-Wahl), cluster_dashboard.png, cluster_metrics_heatmap.png, cluster_radar_chart.png, Sub-Cluster_Vergleich_dashboard.png

Dashboards: users_dashboard.png, sessions_dashboard.png, Flights_Dashboard_1–3.png, Hotels_Analysis_Dashboard.png, Hotels_Cleaning_Dashboard.png

Fazit & mögliche nächste Schritte

Fazit: Die Kombination aus regelbasierter Segmentierung und unüberwachtem K-Means-Clustering liefert ein belastbares, unmittelbar nutzbares Kundenbild: eine kleine, hochwertige Wertkundschaft, eine große, preissensible Mittelschicht und eine rabatt-/stornokritische Gruppe. Damit lassen sich Marketingbudget und Retention-Maßnahmen gezielt steuern.

- Segmentierte Kampagnen umsetzen (VIP-Loyalty für Cluster 0, Aktivierung für Cluster 1, Non-Refundable-/Rabatt-Steuerung für Cluster 2).
- Cross-Selling ausbauen (Hotel zu Flug bzw. Flug zu Hotel) und Ancillaries wie Gepäck und Nächte-Upselling fördern.
- KPIs der Segmente laufend monitoren (Conversion, Stornorate, CLV) und Segmente an neuen Daten validieren (z. B. per A/B-Test).
- Technisch: die DB-Verbindung aus Umgebungsvariablen laden statt im Notebook zu hinterlegen.